

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÀI TẬP LỚN

Thuật toán: Differential Evolution

Bài toán truyền thông: Cell free ISAC beamforming

Môn:	Nhập môn kỹ thuật truyền thông
Mã học phần:	IT4593
Mã lớp:	161323
Nhóm sinh viên thực hiện:	38

Họ và tên	MSSV
1. Nông Quốc Cường	20235668
2. Bế Quốc Thành	20235830

HÀ NỘI, tháng 12 năm 2025

MỤC LỤC

PHẦN 1: THUẬT TOÁN DIFFERENTIAL EVOLUTION - DE	1
1.1. Mô tả thuật toán cơ bản	1
1.2. Mã giả (Pseudocode)	2
1.3. Mã nguồn (Hàm mục tiêu: $f(x) = x_1^2 + x_2^2$)	3
1.4. Độ phức tạp tính toán (Computational Complexity)	5
1.5. Hội tụ (Convergence)	6
1.6. Các biến thể (Variants)	6
1.7. Ứng dụng giải bài toán	9
PHẦN 2: PHÂN TÍCH HỆ THỐNG VÀ BÀI TOÁN TỐI ƯU	12
2.1. Tóm tắt hệ thống truyền thông	12
2.2. Mô hình hệ thống và thiết lập bài toán	12
2.2.1. Các thuật ngữ và ký hiệu chính	12
2.2.2. Mô hình Tín hiệu phát (Signal Model)	13
2.2.3. Mô hình Truyền thông (Communication Model)	13
2.2.4. Mô hình Cảm biến (Sensing Model)	14
2.2.5. Phát biểu Bài toán Tối ưu hóa	15
PHẦN 3: BÁO CÁO ĐÁNH GIÁ HIỆU NĂNG: TỐI ƯU HÓA BEAMFORMING CHO ISAC CELL-FREE SỬ DỤNG THUẬT TOÁN TIẾN HÓA LAI GHEP	16
3.1. Giới thiệu và phạm vi nghiên cứu	16
3.2. Các phương pháp so sánh	16
3.3. Phân tích kết quả mô phỏng	16
3.3.1. Thiết lập mô phỏng	16
3.3.2. Phân tích theo Tỷ lệ phân bổ công suất	18
3.3.3. Phân tích theo Khoảng cách người dùng	19
3.4. Đánh giá độ phức tạp tính toán và khả năng thực thi	19
3.4.1. Phân tích độ phức tạp theo số chiều bài toán	19
3.4.2. Hiệu quả hội tụ của cơ chế Lai ghép	20
3.5. Nhận xét và kết luận	20
3.5.1. Nhận xét các phương pháp Differential Evolution	20
3.5.2. Kết luận	21
Tài liệu tham khảo	22

DANH SÁCH HÌNH

Hình 1. So sánh tốc độ hội tụ trên hàm Rastrigin, $D = 5$	10
Hình 2. So sánh hiệu năng SINR truyền thông và SNR cảm biến theo sự thay đổi của tỷ lệ công suất truyền thông (ρ).	18
Hình 3. Hiệu năng hệ thống ISAC khi thay đổi khoảng cách giữa người dùng (UE) và mục tiêu (Target).	19

PHẦN 1: THUẬT TOÁN DIFFERENTIAL EVOLUTION - DE

1.1. Mô tả thuật toán cơ bản

Di truyền vi sai (Differential Evolution - DE) là một thuật toán tối ưu hóa metaheuristic (siêu phỏng nghiệm) dựa trên quần thể, được giới thiệu bởi Storn và Price vào năm 1997. Nó thuộc nhóm các thuật toán tiến hóa, tương tự như Thuật toán Di truyền (Genetic Algorithm - GA), nhưng có cơ chế đột biến và tái tổ hợp khác biệt, giúp nó đặc biệt hiệu quả cho các bài toán tối ưu toàn cục với biến liên tục.

Ý tưởng cốt lõi của DE là sử dụng sự sai khác (differential) của các vector (cá thể) trong quần thể hiện tại để tạo ra các cá thể mới cho thế hệ tiếp theo.

Quá trình hoạt động của DE cơ bản (phiên bản DE/rand/1/bin) bao gồm các bước sau:

- **Bước 1. Khởi tạo (Initialization):** Một quần thể N cá thể (vector) được khởi tạo ngẫu nhiên trong không gian tìm kiếm D chiều. Mỗi cá thể x_i (với $i = 1, \dots, N$) là một vector giải pháp tiềm năng.

$$x_{j,i,G=0} = x_{j,min} + rand(0,1) \cdot (x_{j,max} - x_{j,min})$$

trong đó $j = 1, \dots, D$ là chiều thứ j của cá thể i tại thế hệ $G = 0$.

- **Bước 2. Đột biến (Mutation):** Với mỗi cá thể "mục tiêu" $x_{i,G}$ trong quần thể, một "vector đột biến" $v_{i,G}$ được tạo ra. Chiến lược đột biến phổ biến nhất (DE/rand/1) là:

$$v_{i,G} = x_{r1,G} + F \cdot (x_{r2,G} - x_{r3,G})$$

trong đó:

- $r1, r2, r3$ là các chỉ số được chọn ngẫu nhiên, phân biệt lẫn nhau và khác với i (tức là $r1 \neq r2 \neq r3 \neq i$).
- F là **hệ số co giãn (scaling factor)** (thường trong khoảng $[0.4, 1.0]$), kiểm soát mức độ "khuếch đại" của vector sai khác.
- **Bước 3. Tái tổ hợp (Recombination / Crossover):** Một "vector thử nghiệm" $u_{i,G}$ được tạo ra bằng cách kết hợp vector mục tiêu $x_{i,G}$ và vector đột biến $v_{i,G}$. Phương pháp phổ biến là "binomial crossover":

$$u_{j,i,G} = \begin{cases} v_{j,i,G} & \text{nếu } (rand(0,1) \leq CR) \text{ hoặc } (j = j_{rand}) \\ x_{j,i,G} & \text{ngược lại} \end{cases}$$

trong đó:

- CR là **tỷ lệ tái tổ hợp (crossover rate)** (thường trong khoảng $[0.1, 1.0]$), kiểm soát xác suất mà gen của vector đột biến được "thừa hưởng".
- j_{rand} là một chỉ số được chọn ngẫu nhiên từ $[1, D]$, đảm bảo vector thử

nhận được ít nhất một thành phần từ vector đột biến $v_{i,G}$.

- **Bước 4. Lựa chọn (Selection):** Vector thử nghiệm $u_{i,G}$ được so sánh với vector mục tiêu $x_{i,G}$ dựa trên hàm mục tiêu (fitness function) $f(x)$.
 - Nếu $u_{i,G}$ tốt hơn (ví dụ, $f(u_{i,G}) \leq f(x_{i,G})$ đối với bài toán cực tiểu hóa), thì $u_{i,G}$ sẽ thay thế $x_{i,G}$ trong thế hệ tiếp theo.
 - Ngược lại, $x_{i,G}$ được giữ lại.

$$x_{i,G+1} = \begin{cases} u_{i,G} & \text{nếu } f(u_{i,G}) \leq f(x_{i,G}) \\ x_{i,G} & \text{ngược lại} \end{cases}$$

Bốn bước này được lặp lại cho đến khi đạt được điều kiện dừng (ví dụ: đủ số thế hệ G_{max} hoặc độ cải thiện không còn đáng kể).

1.2. Mã giả (Pseudocode)

Dưới đây là mã giả cho thuật toán DE cơ bản (ví dụ: DE/rand/1/bin):

BEGIN

// 1. Khởi tạo

Khởi tạo quần thể $P = \{x_1, x_2, \dots, x_N\}$ với N cá thể ngẫu nhiên trong không gian D chiều.

Tính toán giá trị fitness $f(x_i)$ cho tất cả cá thể x_i trong P .

// Bắt đầu vòng lặp các thế hệ

FOR $G = 1$ TO G_{max} DO

// Lặp qua từng cá thể trong quần thể

FOR $i = 1$ TO N DO

// 2. Đột biến

// Chọn ngẫu nhiên $r1, r2, r3$ từ $\{1, \dots, N\}$ sao cho $r1 \neq r2 \neq r3 \neq i$

Chọn $r1, r2, r3$

// Tạo vector đột biến

$v_i = x_{r1} + F * (x_{r2} - x_{r3})$

// (Tùy chọn: Xử lý các giá trị của v_i nếu chúng vượt ra ngoài biên (bounds))

// 3. Tái tổ hợp (Binomial Crossover)

Tạo vector thử nghiệm u_i

Chọn ngẫu nhiên j_{rand} từ $\{1, \dots, D\}$

FOR $j = 1$ TO D DO

IF ($\text{rand}(0,1) \leq CR$) OR ($j == j_{rand}$) THEN

$u_{j,i} = v_{j,i}$

ELSE

$u_{j,i} = x_{j,i}$

END IF

END FOR

```

// 4. Lựa chọn
Tính toán giá trị f(u_i)
IF f(u_i) tốt hơn f(x_i) THEN // (Ví dụ: f(u_i) <= f(x_i) cho bài toán min)
    x_i = u_i // Thay thế cá thể cũ bằng cá thể mới
END IF
END FOR
END FOR

// Kết quả
Trả về cá thể tốt nhất (best_solution) tìm thấy trong quần thể.
END

```

1.3. Mã nguồn (Hàm mục tiêu: $f(x) = x_1^2 + x_2^2$)

Thực thi thuật toán DE/rand/1/bin tối ưu hóa theo hướng minimize.

Các Tham số:

- fitness_func: Hàm mục tiêu cần tối ưu (minimize)
- lower_bound: Biên dưới của không gian tìm kiếm
- upper_bound: Biên trên của không gian tìm kiếm
- pop_size (N): Kích thước quần thể
- dim (D): Số chiều của bài toán
- F: Hệ số co giãn (Scaling Factor)
- CR (P_{cr}): Xác suất lai ghép (Crossover Probability)
- max_gen: Số thế hệ tối đa (điều kiện dừng)

```
import numpy as np
```

```
# Hàm mục tiêu: f(x) = x1^2 + x2^2
```

```
def fitness_function(solution):
    return np.sum(solution**2)
```

```
def differential_evolution(fitness_func, lower_bound, upper_bound, pop_size,
dim, F, CR, max_gen):
```

```
    """
```

```
    DE/rand/1/bin tối thiểu hóa hàm fitness.
```

```
    Tham số chính: lower_bound, upper_bound, pop_size, dim, F, CR, max_gen.
```

```
    Trả về: best_solution, best_fitness
```

```
    """
```

```
    # Khởi tạo quần thể và fitness
```

```
    pop = lower_bound + (upper_bound - lower_bound) *
```

```
    np.random.rand(pop_size, dim)
```

```
    fitness = np.array([fitness_func(ind) for ind in pop])
```

```

best_idx = np.argmin(fitness)
best_solution = pop[best_idx].copy()
best_fitness = fitness[best_idx]

print(f'--- BẮT ĐẦU THUẬT TOÁN DE ---')
print(f'Quần thể ban đầu, Best Fitness: {best_fitness:.6f}')

for g in range(max_gen):
    for i in range(pop_size):
        parent_vector = pop[i]

        # Mutation:  $v = x_{r1} + F \cdot (x_{r2} - x_{r3})$ 
        indices = [idx for idx in range(pop_size) if idx != i]
        r1, r2, r3 = np.random.choice(indices, 3, replace=False)
        trial_vector = pop[r1] + F * (pop[r2] - pop[r3])
        trial_vector = np.clip(trial_vector, lower_bound, upper_bound) # bounds
handling

        # Crossover (binomial)
        offspring_vector = parent_vector.copy()
        j_rand = np.random.randint(0, dim)
        for j in range(dim):
            if np.random.rand() < CR or j == j_rand:
                offspring_vector[j] = trial_vector[j]

        # Selection
        offspring_fitness = fitness_func(offspring_vector)
        if offspring_fitness < fitness[i]:
            pop[i] = offspring_vector
            fitness[i] = offspring_fitness
            if offspring_fitness < best_fitness:
                best_fitness = offspring_fitness
                best_solution = offspring_vector.copy()

    print(f'Thế hệ {g+1}/{max_gen}, Best Fitness: {best_fitness:.6f}')

print(f'--- KẾT THÚC ---')
return best_solution, best_fitness

if __name__ == "__main__":
    POP_SIZE = 5
    DIMENSION = 2
    LOWER_BOUND = -5

```

```

UPPER_BOUND = 5
F_FACTOR = 0.5
CR_RATE = 0.7
MAX_GEN = 50

final_solution, final_fitness = differential_evolution(
    fitness_function,
    LOWER_BOUND,
    UPPER_BOUND,
    POP_SIZE,
    DIMENSION,
    F_FACTOR,
    CR_RATE,
    MAX_GEN
)

print(f'\nGiải pháp tốt nhất tìm được: {final_solution}')
print(f'Giá trị Fitness tốt nhất: {final_fitness:.6f}')
print(f'(Đáp án lý tưởng: [0, 0], fitness = 0.0)')

```

1.4. Độ phức tạp tính toán (Computational Complexity)

Độ phức tạp tính toán của DE phụ thuộc chủ yếu vào các yếu tố:

1. N : Kích thước quần thể (Population size).
2. D : Số chiều của bài toán (Dimension of the problem).
3. G_{max} : Số thế hệ tối đa (Maximum generations).
4. $C_{f(x)}$: Chi phí tính toán hàm mục tiêu (fitness function) cho một giải pháp.

Trong mỗi thế hệ G :

- **Đột biến:** Đối với mỗi cá thể i (từ 1 đến N), ta cần thực hiện các phép toán vector D chiều (chọn 3 cá thể, 1 phép trừ, 1 phép nhân vô hướng, 1 phép cộng). Độ phức tạp là $O(N \cdot D)$.
- **Tái tổ hợp:** Đối với mỗi cá thể i , ta lặp qua D chiều. Độ phức tạp là $O(N \cdot D)$.
- **Tính toán Fitness:** Tính fitness cho N vector thử nghiệm u_i . Độ phức tạp là $O(N \cdot C_{f(x)})$.
- **Lựa chọn:** So sánh N cặp fitness. Độ phức tạp là $O(N)$.

Tổng độ phức tạp cho một thế hệ là: $O(N \cdot D + N \cdot D + N \cdot C_{f(x)} + N) \approx O(N \cdot (D + C_{f(x)}))$.

Tổng độ phức tạp tính toán của toàn bộ thuật toán DE là: $O(G_{max} \cdot N \cdot (D + C_{f(x)}))$.

$$(D + C_{f(x)})$$

Trong nhiều bài toán kỹ thuật (như bài toán beamforming), chi phí đánh giá hàm mục tiêu $C_{f(x)}$ (ví dụ: tính toán SINR, tỷ lệ dữ liệu từ các vector beamforming) thường là nút thắt cổ chai và lớn hơn D rất nhiều.

1.5. Hội tụ (Convergence)

Tính chất: DE là một thuật toán tìm kiếm ngẫu nhiên (stochastic). Giống như các thuật toán metaheuristic khác, nó **không đảm bảo** tìm thấy cực trị tối ưu toàn cục (global optimum) trong một thời gian hữu hạn.

Cơ chế:

- **Khám phá (Exploration):** Khả năng tìm kiếm ở các vùng rộng lớn của không gian. Điều này được thúc đẩy bởi toán tử đột biến (sử dụng sai khác của các vector ngẫu nhiên).
- **Khai thác (Exploitation):** Khả năng tìm kiếm tinh vi (local search) xung quanh các giải pháp tốt đã tìm thấy. Điều này được thúc đẩy bởi toán tử lựa chọn (chỉ giữ lại các giải pháp tốt hơn).

Ảnh hưởng của tham số:

- **F (Scaling Factor):** F nhỏ (ví dụ: 0.4) làm cho bước nhảy nhỏ, tăng cường khai thác (exploitation) nhưng có thể hội tụ sớm vào cực trị địa phương. F lớn (ví dụ: 0.9) làm bước nhảy lớn, tăng cường khám phá (exploration) nhưng có thể làm chậm quá trình hội tụ.
- **CR (Crossover Rate):** CR cao (ví dụ: 0.9) làm cho vector thử nghiệm u_i giống vector đột biến v_i hơn, tăng cường khám phá. CR thấp (ví dụ: 0.1) làm cho u_i giống vector mục tiêu x_i hơn, tăng cường khai thác.

Định lý "No Free Lunch" (NFL): Không có một thuật toán tối ưu nào là tốt nhất cho *mọi* loại bài toán. DE tỏ ra rất mạnh mẽ trên các bài toán có hàm mục tiêu không tuyến tính, không liên tục, đa cực trị (multimodal), nhưng có thể hoạt động không hiệu quả bằng các phương pháp dựa trên gradient (gradient-based) cho các bài toán lồi (convex).

1.6. Các biến thể (Variants)

Các biến thể của DE chủ yếu khác nhau ở chiến lược **đột biến** và đôi khi ở chiến lược **tái tổ hợp**. Ký hiệu chung là DE/x/y/z:

- x: Chiến lược chọn vector cơ sở (base vector).
- y: Số lượng cặp vector sai khác được sử dụng.
- z: Kiểu tái tổ hợp (ví dụ: bin cho binomial, exp cho exponential).

Một số biến thể phổ biến:

1. **DE/rand/1/bin:** (Đã mô tả ở trên) $v_i = x_{r1} + F \cdot (x_{r2} - x_{r3})$

- *Ưu điểm*: Khả năng khám phá tốt, tránh bị kẹt ở cực trị địa phương.
 - *Nhược điểm*: Tốc độ hội tụ có thể chậm.
2. **DE/best/1/bin**: $v_i = x_{best} + F \cdot (x_{r1} - x_{r2})$ (trong đó x_{best} là cá thể tốt nhất trong quần thể hiện tại)
- *Ưu điểm*: Hội tụ rất nhanh do "tham lam" hướng về giải pháp tốt nhất.
 - *Nhược điểm*: Rất dễ bị kẹt ở cực trị địa phương (premature convergence).
3. **DE/current-to-best/1/bin**: $v_i = x_i + F \cdot (x_{best} - x_i) + F \cdot (x_{r1} - x_{r2})$
- *Ưu điểm*: Kết hợp thông tin từ cá thể hiện tại (x_i) và cá thể tốt nhất (x_{best}), tạo ra sự cân bằng tốt giữa khám phá và khai thác.
4. **DE/best/2/bin**: $v_i = x_{best} + F \cdot (x_{r1} - x_{r2}) + F \cdot (x_{r3} - x_{r4})$
- Sử dụng hai cặp vector sai khác. Tăng cường khả năng khám phá, hữu ích cho các bài toán phức tạp, đa cực trị.
5. **DE/rand-to-best/1/bin**: $v_i = x_{r1} + F \cdot (x_{best} - x_{r1}) + F \cdot (x_{r2} - x_{r3})$
- Một biến thể cân bằng khác.

Các **biến thể thích ứng (Adaptive DE)**: Các tham số F và CR có ảnh hưởng rất lớn đến hiệu suất của DE. Các biến thể hiện đại như **JADE** (Adaptive DE with optional external archive) và **SHADE** (Success-History based Adaptive DE) không sử dụng các giá trị F , CR cố định, mà tự động "học" và điều chỉnh các tham số này trong quá trình chạy dựa trên "thành công" của các giá trị trước đó. Đây thường là các lựa chọn hàng đầu khi áp dụng DE vào thực tế.

6. JADE (Adaptive Differential Evolution with Optional External Archive)

JADE được đề xuất bởi Zhang và Sanderson (2009), đưa ra hai cải tiến quan trọng giúp thuật toán vừa hội tụ nhanh vừa duy trì sự đa dạng:

- a) **Chiến lược đột biến mới: DE/current-to-pbest/1** Thay vì chọn ngẫu nhiên hay chọn cá thể tốt nhất tuyệt đối, JADE sử dụng chiến lược:

$$v_{i,G} = x_{i,G} + F_i \cdot (x_{pbest,G} - x_{i,G}) + F_i \cdot (x_{r1,G} - x_{r2,G})$$

trong đó:

- $x_{pbest,G}$: Là một cá thể được chọn ngẫu nhiên từ top $p\%$ cá thể tốt nhất trong quần thể hiện tại (ví dụ top 5% hay 10%). Giúp tận dụng thông tin tốt mà không bị hội tụ sớm như DE/best/1.
- $x_{r1,G}$: Được chọn từ quần thể hiện tại P .
- $x_{r2,G}$: Được chọn từ hợp tập của quần thể hiện tại P và một **tập lưu trữ bên ngoài (Archive A)**. Tập A chứa các cá thể kém hơn vừa bị thay thế, giúp duy trì sự đa dạng gen lịch sử.

b) **Thích nghi tham số (Parameter Adaptation)** Tại mỗi thế hệ, F_i và CR_i cho từng cá thể i được sinh ra độc lập dựa trên phân phối xác suất:

- $CR_i = randn(\mu_{CR}, 0.1)$
- $F_i = randc(\mu_F, 0.1)$

Các giá trị trung bình μ_{CR} và μ_F được cập nhật liên tục dựa trên tập hợp các giá trị F và CR đã tạo ra các cá thể con thành công ở thế hệ trước.

7. SHADE (Success-History based Adaptive Differential Evolution)

SHADE (Tanabe & Fukunaga, 2013) là bước phát triển vượt bậc của JADE và được coi là một trong những thuật toán DE mạnh mẽ nhất hiện nay. Điểm yếu của JADE là chỉ sử dụng một cặp giá trị trung bình (μ_{CR} , μ_F) duy nhất để hướng dẫn sinh tham số cho toàn bộ quá trình. Điều này có thể không tối ưu vì các giai đoạn tìm kiếm khác nhau (giai đoạn đầu cần khám phá, giai đoạn sau cần khai thác) thường đòi hỏi các bộ tham số khác nhau.

SHADE giải quyết vấn đề này bằng cơ chế **Bộ nhớ lịch sử thành công (Success History Memory)**.

a) **Cơ chế Bộ nhớ Lịch sử (History Memory - H)** SHADE duy trì một bộ nhớ lịch sử H có kích thước cố định (thường là $|H| = 100$). Bộ nhớ này lưu trữ một tập hợp các cặp giá trị trung bình đã thành công trong quá khứ:

$$M = \{ (M_{CR,1}, M_{F,1}), (M_{CR,2}, M_{F,2}), \dots, (M_{CR,|H|}, M_{F,|H|}) \}$$

Ban đầu, tất cả các giá trị trong bộ nhớ được khởi tạo là 0.5.

b) **Sinh tham số thích nghi** Tại mỗi thế hệ G , với mỗi cá thể i , thuật toán chọn ngẫu nhiên một chỉ số r_i từ 1 đến $|H|$. Tham số F_i và CR_i được sinh ra dựa trên giá trị trung bình tại vị trí r_i trong bộ nhớ:

- **Tỷ lệ lai ghép CR_i :** Được sinh từ phân phối chuẩn (Normal distribution) với trung bình M_{CR,r_i} và độ lệch chuẩn 0.1:

$$CR_i = randn(M_{CR,r_i}, 0.1)$$

(Giá trị CR_i được cắt về đoạn $[0, 1]$).

- **Hệ số co giãn F_i :** Được sinh từ phân phối Cauchy với tham số vị trí M_{F,r_i} và tham số tỉ lệ 0.1:

$$F_i = randc(M_{F,r_i}, 0.1)$$

(Nếu $F_i \leq 0$, sinh lại; nếu $F_i > 1$, gán bằng 1).

c) **Cập nhật Bộ nhớ Lịch sử** Sau mỗi thế hệ, SHADE thu thập tất cả các cặp (CR_i, F_i) đã tạo ra cá thể con u_i tốt hơn cha mẹ x_i (tức là $f(u_i) < f(x_i)$). Gọi tập hợp này là S_{CR} và S_F . Độ cải thiện về hàm mục tiêu $\Delta f_k = |f(u_k) - f(x_k)|$ được dùng làm trọng số.

Bộ nhớ tại vị trí k (với k chạy vòng tròn từ 1 đến $|H|$) được cập nhật bằng **Trung bình Lehmer có trọng số (Weighted Lehmer Mean)**:

$$M_{CR,k} = mean_{WL}(S_{CR}) = \frac{\sum_{k \in S} w_k \cdot S_{CR,k}}{\sum_{k \in S} w_k}$$

$$M_{F,k} = mean_{WL}(S_F) = \frac{\sum_{k \in S} w_k \cdot S_{F,k}^2}{\sum_{k \in S} w_k \cdot S_{F,k}}$$

với trọng số $w_k = \frac{\Delta f_k}{\sum \Delta f_k}$.

Việc sử dụng trung bình Lehmer và trọng số dựa trên độ cải thiện giúp SHADE ưu tiên các tham số tạo ra bước đột phá lớn về chất lượng, thay vì chỉ đếm số lượng thành công. Điều này giúp thuật toán cực kỳ bền vững và hiệu quả trên các bài toán đa cực trị phức tạp.

1.7. Ứng dụng giải bài toán

Mô tả bài toán: Mục tiêu là tìm các giá trị đầu vào x_i (các biến liên tục) sao cho giá trị của hàm $f(x)$ đạt **cực tiểu toàn cục**.

Hàm mục tiêu f :

Công thức toán học của hàm Rastrigin cho n chiều (với $n \geq 2$) như sau:

$$f(x) = A \cdot n + \sum_{i=1}^n [x_i^2 - A \cdot \cos(2\pi x_i)]$$

Trong đó:

- $x = (x_1, x_2, \dots, x_n)$ là vector các biến đầu vào (đây là các tham số mà thuật toán DE cần tối ưu).
- $A = 10$ (hằng số, thường dùng giá trị 10).
- n là số chiều của bài toán (ví dụ: $n = 2$ hoặc $n = 10$).
- x_i thường nằm trong khoảng giới hạn, ví dụ: $x_i \in [-5.12, 5.12]$ cho mọi i .

MÔ PHỎNG VÀ ĐÁNH GIÁ HIỆU NĂNG

Sau khi tìm hiểu lý thuyết và cài đặt thuật toán, phần này sẽ tập trung vào việc so sánh hiệu năng thực tế của các biến thể DE trên bài toán tối ưu hóa hàm đa cực trị.

a) Thiết lập môi trường thực nghiệm

Để kiểm chứng khả năng thoát khỏi các cực trị địa phương (local optima), nhóm thực hiện mô phỏng trên hàm **Rastrigin**. Đây là hàm mục tiêu có độ phức tạp cao với hàng ngàn điểm cực trị địa phương, thường được dùng làm chuẩn (benchmark) để đánh giá các thuật toán tối ưu.


Thông số cấu hình:

- **Hàm mục tiêu:** Rastrigin Function ($D = 5$ chiều).
- **Kích thước quần thể (Population Size):** $N = 100$.
- **Số thế hệ tối đa (Max Generations):** $G_{max} = 1000$.
- **Số lần chạy thực nghiệm:** Kết quả được lấy trung bình để đảm bảo tính khách quan.
- **Các thuật toán được so sánh:**
 - **DE/rand/1/bin (Xanh):** Đại diện cho nhóm cổ điển (tham số cố định).
 - **DE/current-to-best/1/bin (Cam):** Đại diện cho nhóm cải tiến hướng đích.
 - **SHADE (Đỏ):** Đại diện cho nhóm thích nghi tham số (Adaptive).

b) Phân tích kết quả mô phỏng

Mã nguồn: https://github.com/FIRaci/DE/blob/main/compare_de.py

Kết quả chạy mô phỏng tốc độ hội tụ của ba thuật toán được thể hiện trong hình dưới đây (trục tung sử dụng thang đo Logarit để hiển thị rõ độ chính xác ở các giá trị nhỏ)



Hình 1. So sánh tốc độ hội tụ trên hàm Rastrigin, $D = 5$.

Dựa vào đồ thị, ta có những phân tích chi tiết về hành vi của từng thuật toán như sau:

- Đối với **DE/rand/1/bin** (Đường nét đứt màu xanh)
 - **Hiện tượng:** Thuật toán hội tụ chậm nhất trong ba ứng viên. Đồ thị có dạng "bậc thang" rõ rệt: đi ngang một đoạn rồi mới tụt xuống. Phải đến khoảng thế hệ thứ 540, thuật toán mới tìm được cực trị toàn cục (Fitness $\rightarrow 0$).
 - **Đánh giá:** Do không gian 5 chiều vẫn chứa các cực trị địa phương, chiến lược đột biến ngẫu nhiên (rand) mất nhiều thời gian để mò mẫm tìm ra hướng

đi đúng. Dạng bậc thang cho thấy thuật toán thỉnh thoảng bị kẹt nhẹ rồi mới thoát ra được.

- Đối với **DE/current-to-best/1/bin** (Đường chấm gạch màu cam)
 - **Hiện tượng:** Về đích sớm nhất. Tốc độ giảm lỗi rất nhanh và dứt khoát. Tại thế hệ khoảng 260, nó đã tìm ra nghiệm tối ưu hoàn toàn, nhanh gấp đôi so với rand/1
 - **Đánh giá:** Ở số chiều thấp ($D = 5$), không gian tìm kiếm không quá phức tạp. Chiến lược "tham lam" hướng về cá thể tốt nhất (current-to-best) phát huy tác dụng tối đa: nó dẫn dắt quần thể lao thẳng về đích mà không bị kẹt vào các bẫy địa phương (điều thường xảy ra ở số chiều cao)
- Đối với **SHADE** (Đường liền màu đỏ)
 - **Hiện tượng:** SHADE bám đuổi rất sát nút với current-to-best. Tốc độ hội tụ ổn định và mượt mà hơn, không bị giật cục như rand/1. Thuật toán về đích tại khoảng thế hệ 330, chậm hơn một chút so với DE/current-to-best/1/bin.
 - **Đánh giá:** Mặc dù SHADE là thuật toán hiện đại nhất, nhưng cơ chế "thích nghi tham số" cần một khoảng thời gian để "học" (warm-up). Trong các bài toán đơn giản hoặc số chiều thấp, đôi khi sự cần trọng của SHADE khiến nó chậm hơn một chút so với chiến lược tấn công trực diện của current-to-best. Tuy nhiên, kết quả cho thấy SHADE vẫn hoạt động cực kỳ hiệu quả và tin cậy.

c) Kết luận

- Độ phức tạp của bài toán: Với số chiều thấp, cả 3 biến thể DE đều có khả năng giải quyết triệt để bài toán Rastrigin (tìm được nghiệm bằng 0). Không xảy ra hiện tượng ngưng trệ vĩnh viễn.
- Chiến lược hướng đích (current-to-best) là lựa chọn tối ưu nhất về tốc độ cho các bài toán có số chiều nhỏ.
- SHADE chứng tỏ sự ổn định cao, dù tốc độ có thể thua kém nhẹ so với các chiến lược chuyên biệt ở các bài toán đơn giản, nhưng bù lại nó đảm bảo độ tin cậy.

PHẦN 2: PHÂN TÍCH HỆ THỐNG VÀ BÀI TOÁN TỐI ƯU

Nguồn tham khảo <https://github.com/umut-demirhan/Cell-free-ISAC-beamforming>

2.1. Tóm tắt hệ thống truyền thông

Hệ thống được mô tả trong bài báo là một mạng **Cell-free Massive MIMO ISAC** (Hệ thống đa ăng-ten phi tế bào tích hợp cảm biến và truyền thông). Đây là một bước tiến quan trọng hướng tới mạng 6G, nơi ranh giới giữa các trạm phát sóng bị xóa bỏ và chức năng cảm biến được tích hợp sâu vào mạng lưới.

- **Kiến trúc Cell-free Massive MIMO:** Hệ thống bao gồm một số lượng lớn các Điểm truy cập (Access Points - APs) phân tán về mặt địa lý.
 - Các AP này không hoạt động độc lập theo từng "tế bào" (cell) riêng biệt mà phối hợp đồng bộ với nhau thông qua một Bộ xử lý trung tâm (CPU) để phục vụ người dùng.
 - Tập hợp các AP phát ($\mathcal{M}_t$) và AP thu ($\mathcal{M}_r$) cùng hợp tác để phục vụ các thiết bị người dùng (UEs) và cảm biến môi trường.
- **Cơ chế ISAC (Integrated Sensing and Communication):**
 - Hệ thống sử dụng chung hạ tầng phần cứng và tài nguyên vô tuyến để thực hiện đồng thời hai chức năng:
 - **Truyền thông đường xuống (Downlink Communication):** Truyền dữ liệu từ các AP đến U người dùng đơn ăng-ten.
 - **Cảm biến (Sensing):** Phát hiện và ước lượng thông tin của "Mục tiêu" (Target) bằng cách thu nhận tín hiệu phản xạ (echo) từ mục tiêu đó tại các AP thu.
 - Mô hình cảm biến được sử dụng là **Multi-static sensing** (Cảm biến đa tĩnh), trong đó tín hiệu phát từ nhiều AP khác nhau phản xạ qua mục tiêu và được thu lại bởi nhiều AP khác nhau để tổng hợp thông tin.
- **Tín hiệu phát:**
 - Mỗi AP phát đi một tín hiệu tổng hợp bao gồm cả tín hiệu dữ liệu (cho người dùng) và tín hiệu chuyên dụng cho cảm biến (sensing signal). Các tín hiệu này được trộn lẫn và điều hướng bằng kỹ thuật **Beamforming** (Tạo búp sóng).

2.2. Mô hình hệ thống và thiết lập bài toán

Hệ thống Cell-Free ISAC được mô hình hóa toán học dựa trên ba thành phần chính: Mô hình tín hiệu phát, Mô hình kênh truyền thông, và Mô hình kênh cảm biến.

2.2.1. Các thuật ngữ và ký hiệu chính

Trước khi đi vào chi tiết mô hình, các ký hiệu và thuật ngữ cơ bản được định nghĩa

như sau:

- **AP (Access Point):** Điểm truy cập. Hệ thống gồm M AP, được chia thành tập hợp AP phát ($\mathcal{M}_t$) và AP thu ($\mathcal{M}_r$).
- **UE (User Equipment):** Thiết bị người dùng. Hệ thống phục vụ đồng thời U người dùng đơn ăng-ten ($\mathcal{U} = \{1, \dots, U\}$).
- **Beamforming Vector ($\mathbf{f}_{ms}$):** Vector trọng số phức quyết định hướng và công suất phát của tín hiệu từ AP m cho luồng dữ liệu s . Đây là biến số cần tối ưu hóa.
- **SINR (Signal-to-Interference-plus-Noise Ratio):** Tỷ số tín hiệu trên nhiễu cộng tạp âm. Chỉ số đo lường chất lượng kết nối của người dùng.
- **Sensing SNR:** Tỷ số tín hiệu trên tạp âm của cảm biến. Chỉ số đo lường khả năng phát hiện mục tiêu của hệ thống radar.

2.2.2. Mô hình Tín hiệu phát (Signal Model)

Trong hệ thống ISAC, mỗi AP phát đi một tín hiệu tổng hợp chứa cả thông tin liên lạc và tín hiệu thăm dò. Tín hiệu phát $x_m[l]$ tại AP m ở thời điểm l được biểu diễn như sau:

$$x_m[l] = \sum_{u \in U} f_{mu} x_u[l] + \sum_{q \in Q} f_{mq} x_q[l] + \sum_{s \in S} f_{ms} x_s[l]$$

(Tín hiệu Truyền thông) (Tín hiệu Cảm biến)

Trong đó:

- $x_u[l]$ và $x_q[l]$ lần lượt là các ký hiệu dữ liệu gửi cho người dùng u và tín hiệu thăm dò q .
 - $f_{mu} \in \mathbb{C}^{N_t \times 1}$ và $f_{mq} \in \mathbb{C}^{N_t \times 1}$ là các vector beamforming tương ứng tại AP m .
 - $S = U \cup Q$: Tập hợp tất cả các luồng tín hiệu (truyền thông + cảm biến).
- Tín hiệu phát phải tuân thủ ràng buộc công suất tổng tại mỗi AP: $E[|x_m[l]|^2] \leq P_m$.
- P_m : Công suất phát tối đa cho phép tại AP m .

2.2.3. Mô hình Truyền thông (Communication Model)

Tín hiệu thu được tại người dùng u chịu ảnh hưởng bởi kênh truyền, nhiễu đa người dùng (MUI) và đặc biệt là nhiễu từ tín hiệu cảm biến. Tín hiệu thu $y_u^{(c)}[l]$ được mô tả bởi phương trình:

$$y_u^{(c)}[l] = \sum_{m \in \mathcal{M}_t} \mathbf{h}_{mu}^H \mathbf{f}_{mu} x_u[l] + \sum_{u' \in U \setminus \{u\}} \sum_{m \in \mathcal{M}_t} \mathbf{h}_{mu}^H \mathbf{f}_{mu'} x_{u'}[l] + \sum_{q \in Q} \sum_{m \in \mathcal{M}_t} \mathbf{h}_{mu}^H \mathbf{f}_{mq} x_q[l] + n_u[l]$$

(Tín hiệu mong muốn) (Nhiễu đa người dùng (MUI)) (Nhiễu cảm biến (SI))

Trong đó:

- $\mathbf{h}_{mu} \in \mathcal{C}^{N_t \times 1}$ là vector kênh truyền tổng hợp từ tất cả các AP đến người dùng u .
- $n_u[l] \sim \mathcal{CN}(0, \sigma_u^2)$: Nhiễu nhiệt tại máy thu người dùng với phương sai σ_u^2 .

Chất lượng dịch vụ của người dùng u được đánh giá qua chỉ số SINR:

$$SINR_u = \frac{|\mathbf{h}_u^H \mathbf{f}_u|^2}{\sum_{u' \neq u} |\mathbf{h}_u^H \mathbf{f}_{u'}|^2 + \sum_{q \in Q} |\mathbf{h}_u^H \mathbf{f}_q|^2 + \sigma_u^2}$$

Trong đó:

- $\mathbf{h}_u$ là vector kênh truyền tổng hợp từ tất cả các AP đến người dùng u .
- $\mathbf{f}_u$ Vector beamforming tổng hợp cho người dùng u .

Mục tiêu của bài toán tối ưu là đảm bảo $SINR_u$ vượt qua một ngưỡng tối thiểu γ_u cho trước.

2.2.4. Mô hình Cảm biến (Sensing Model)

Hệ thống sử dụng mô hình cảm biến đa tĩnh (multi-static sensing). Tín hiệu phát từ các AP $\mathcal{M}_t$ phản xạ qua mục tiêu (target) và được thu lại bởi các AP $\mathcal{M}_r$.

Kênh cảm biến từ AP phát m_t đến AP thu m_r qua mục tiêu được mô hình hóa là:

$$G_{m_t m_r} = \alpha_{m_t m_r} a(\theta_{m_r}) a^H(\theta_{m_t})$$

- $\alpha_{m_t m_r}$: Hệ số khuếch đại kênh cảm biến phức (bao gồm pathloss và diện tích phản xạ hiệu dụng RCS).
- $a(\theta)$: Vector phản hồi mảng (Array response vector) tương ứng với góc đi/đến θ .

Tín hiệu phản hồi thu được tại AP m_r là tổng hợp của các tín hiệu phản xạ từ tất cả các luồng phát:

$$y_{m_r}^{(s)}[l] = \sum_{m_t \in \mathcal{M}_t} G_{m_t m_r} x_{m_t}[l] + n_{m_r}[l]$$

Hiệu năng cảm biến được đo lường bằng chỉ số Sensing SNR tổng hợp (sau khi xử lý tín hiệu đồng bộ):

$$SNR^{(s)} = \frac{\sum_{m_r \in \mathcal{M}_r} \sum_{m_t \in \mathcal{M}_t} \zeta_{m_t m_r}^2 \left| a^H(\theta_{m_t}) \bar{\mathbf{F}}_{m_t} \right|^2}{\sum_{m_r \in \mathcal{M}_r} \zeta_{m_r}^2}$$

Trong đó:

- $\zeta_{m_t m_r}^2$: Phương sai của kênh cảm biến (đại diện cho độ mạnh của kênh).
- $\bar{\mathbf{F}}_{m_t}$: Ma trận chứa tất cả các vector beamforming phát từ AP m_t .

Công thức này cho thấy Sensing SNR phụ thuộc trực tiếp vào tổng năng lượng của

các búp sóng hướng về phía mục tiêu (θ_{m_t}).

2.2.5. Phát biểu Bài toán Tối ưu hóa

Dựa trên các mô hình trên, bài toán thiết kế beamforming kết hợp (Joint Sensing and Communication Beamforming) được phát biểu dưới dạng bài toán tối ưu hóa toán học như sau:

Tìm các vector beamforming $\{f_{ms}\}$ để:

- **Tối đa hóa (Maximize):** $SNR^{(s)}$. (1)

- **Thỏa mãn (Subject to):**

• $SINR_u^{(c)} \geq \gamma_u, \forall u \in \mathcal{U}$. (2)

• $\sum_{s \in \mathcal{S}} \|f_{ms}\|^2 \leq P_m, \forall m \in \mathcal{M}_t$ (3)

Trong đó

- Hàm mục tiêu (1): Tối đa hóa Sensing SNR. Ta muốn năng lượng tập trung về hướng mục tiêu là lớn nhất có thể.
- Ràng buộc (2) - Ràng buộc chất lượng truyền thông: Với mỗi người dùng u , tỷ số SINR phải lớn hơn hoặc bằng một ngưỡng γ_u cho trước. Đây là điều kiện tiên quyết để đảm bảo người dùng không bị mất kết nối hoặc rớt mạng do hệ thống tập trung quá nhiều vào việc "soi" mục tiêu.
- Ràng buộc (3) - Ràng buộc công suất: Tổng công suất phát của tất cả các luồng tín hiệu (cho User 1, User 2,... và cho Sensing) tại mỗi AP m không được vượt quá giới hạn phần cứng P_m .

Nhận xét: Đây là một bài toán tối ưu không lồi (Non-convex QCQP) do sự xuất hiện của các biến số beamforming ở cả tử số và mẫu số trong công thức SINR, đồng thời hàm mục tiêu SNR là hàm bậc hai. Việc giải trực tiếp bài toán này rất phức tạp, do đó nhóm nghiên cứu đề xuất sử dụng thuật toán Differential Evolution (DE) và SHADE để tìm kiếm nghiệm tối ưu toàn cục một cách hiệu quả.

PHẦN 3: BÁO CÁO ĐÁNH GIÁ HIỆU NĂNG: TỐI ƯU HÓA BEAMFORMING CHO ISAC CELL-FREE SỬ DỤNG THUẬT TOÁN TIẾN HÓA LAI GHÉP

3.1. Giới thiệu và phạm vi nghiên cứu

Báo cáo này trình bày các kết quả mô phỏng chi tiết nhằm đánh giá hiệu quả của phương pháp tiếp cận lai ghép (Hybrid Approach) đối với hai thuật toán tối ưu hóa meta-heuristic: Differential Evolution (DE) và SHADE. Bài toán đặt ra là tối ưu hóa đồng thời hiệu năng cảm biến (Sensing SNR) và đảm bảo chất lượng thông tin liên lạc (Communication SINR) trong mạng ISAC Cell-free.

Mục tiêu chính là chứng minh rằng việc tích hợp Tri thức Miền (Domain Knowledge) từ các phương pháp giải tích vào quá trình khởi tạo và tìm kiếm của thuật toán tiến hóa có thể khắc phục triệt để các hạn chế về tốc độ hội tụ và khả năng thỏa mãn ràng buộc của các thuật toán nguyên bản.

3.2. Các phương pháp so sánh

JSC (Joint Sensing and Communication): Phương pháp tối ưu hóa dựa trên Quy hoạch Bán xác định (SDP). Đây được coi là đường chuẩn tối ưu (Optimal Benchmark) trong nghiên cứu này.

DE-Hybrid & SHADE-Hybrid (Đề xuất): Các thuật toán tiến hóa được cải tiến với cơ chế khởi tạo dựa trên nghiệm của JSC và Cơ chế Đảm bảo Hiệu năng Cận dưới (Performance Lower-Bound Guarantee), đảm bảo rằng nếu thuật toán tiến hóa không tìm được nghiệm tốt hơn, nó sẽ bảo toàn hiệu năng của JSC làm mức tối thiểu.

DE-Original & SHADE-Original (Đối chứng): Các thuật toán tiến hóa nguyên bản sử dụng khởi tạo ngẫu nhiên tiêu chuẩn và sử dụng hàm phạt nặng để thỏa mãn ràng buộc.

3.3. Phân tích kết quả mô phỏng

Mã nguồn: <https://github.com/FIRaci/DE-Cell-free>

3.3.1. Thiết lập mô phỏng

Để đánh giá hiệu năng của các thuật toán tiến hóa (DE, SHADE) trong bài toán Joint Sensing and Communication (JSC) Beamforming, hệ thống được thiết lập với các thông số chính tương tự mô hình Cell-free Massive MIMO:

a) Môi trường hệ thống:

Mô hình mạng: Cell-free Massive MIMO với số lượng điểm truy cập $\mathcal{M}_r = 2$, mỗi AP trang bị $N_t = 16$ ăng-ten.

Người dùng (UEs): $U = 5$ người dùng đơn ăng-ten được phân bố ngẫu nhiên trong không gian tìm kiếm.

Mục tiêu (Target): $T = 1$ mục tiêu cần giám sát thông qua cơ chế cảm biến đa tĩnh (multi-static sensing).

Kênh truyền: Sử dụng mô hình kênh truyền thẳng (LOS) để mô phỏng sự tương tác

giữa các AP và thiết bị.

b) Cấu hình thuật toán tiến hóa (DE & SHADE):

Số chiều: $D = 320$ chiều.

Kích thước quần thể (N): 50 cá thể.

Số thế hệ tối đa (G_{max}): 200 thế hệ nhằm đảm bảo khả năng tìm kiếm sâu quanh vùng nghiệm tốt nhất.

Hàm mục tiêu: Sử dụng hàm mục tiêu kết hợp: $f(x) = 100 \times \min_SINR + SSNR$, trong đó ưu tiên hàng đầu là thỏa mãn chất lượng truyền thông.


Nhóm Hybrid:

- Khởi tạo định hướng: 1 cá thể được khởi tạo trực tiếp từ nghiệm của thuật toán JSC (SDP).
- Phân bố quần thể: Quần thể được chia thành hai nhóm chiến lược: 30% cá thể tập trung khai thác lân cận (tinh chỉnh với độ *noise* ≈ 0.005) và 70% cá thể thực hiện khám phá toàn cục (mở rộng vùng tìm kiếm với *noise* ≈ 0.15).
- Cơ chế khôi phục: Nếu trong quá trình tiến hóa, các cá thể không tìm được nghiệm tốt hơn, thuật toán sẽ tự động bảo toàn hiệu năng của nghiệm tham chiếu làm ngưỡng sàn (Lower-bound).

Nhóm Original:

- Khởi tạo ngẫu nhiên: Toàn bộ 50 cá thể trong quần thể được khởi tạo ngẫu nhiên trong không gian tìm kiếm 320 chiều ($2 \times U \times M \times N_t$).
- Cơ chế ràng buộc: Do không có nghiệm tham chiếu, thuật toán hoàn toàn phụ thuộc vào hàm phạt (Penalty function) và quy tắc Deb để ép các cá thể di chuyển từ vùng không khả thi vào vùng khả thi.
- Đặc điểm vận hành: Thuật toán tự tìm kiếm đường đi dựa trên các phép đột biến và lai ghép mà không có bất kỳ sự hỗ trợ nào từ các phương pháp tối ưu hóa lỗi truyền thông.

3.3.2. Phân tích theo Tỷ lệ phân bổ công suất



Hình 2. So sánh hiệu năng SINR truyền thông và SNR cảm biến theo sự thay đổi của tỷ lệ công suất truyền thông (ρ).

Hình 2 mô tả hiệu năng hệ thống khi tỷ lệ công suất dành cho truyền thông (ρ) thay đổi từ 0.01 đến 0.99.

Về hiệu năng truyền thông (Communication SINR):

Phương pháp JSC: Duy trì mức tăng trưởng ổn định và đóng vai trò là giới hạn trên lý thuyết.


Giải pháp Lai ghép (Hybrid Algorithms): Các đường đặc tính của DE-Hybrid và SHADE-Hybrid thể hiện sự đồng bộ tuyệt đối với đường JSC. Điều này xác nhận hiệu quả của Cơ chế Khôi phục Nghiệm (Solution Restoration Mechanism): Khi thuật toán tìm kiếm rơi vào vùng không khả thi hoặc có hiệu năng thấp hơn ngưỡng tham chiếu, cơ chế này sẽ tự động hiệu chỉnh nghiệm về trạng thái tối ưu đã biết, đảm bảo SINR không bao giờ bị suy giảm.

Giải pháp Nguyên bản (Original Algorithms): Do không gian tìm kiếm quá lớn ($2 \times U \times M \times N$ chiều) và ràng buộc SINR quá chặt chẽ, các thuật toán khởi tạo ngẫu nhiên thất bại hoàn toàn trong việc tìm kiếm vùng khả thi (Feasible Region), dẫn đến mức SINR xấp xỉ 0 (đường đứt đoạn phía dưới).

Về hiệu năng cảm biến (Sensing SNR):

Các thuật toán Hybrid không chỉ đạt được SINR mục tiêu mà còn duy trì được mức SNR cảm biến tối ưu tương đương với phương pháp giải tích. Điều này chứng tỏ hàm mục tiêu cải tiến ($f(x) = 100 \times \min_SINR + SSNR$) đã điều hướng quá trình tối ưu hóa ưu tiên thỏa mãn ràng buộc truyền thông trước khi tối đa hóa khả năng cảm biến mà không gây ra sai lệch trong sự đánh đổi (trade-off) giữa hai mục tiêu.

3.3.3. Phân tích theo Khoảng cách người dùng



Hình 3. Hiệu năng hệ thống ISAC khi thay đổi khoảng cách giữa người dùng (UE) và mục tiêu (Target).

Hình 3 đánh giá độ bền vững của thuật toán trước sự biến đổi của điều kiện kênh truyền (thông qua thay đổi khoảng cách hình học).

Tính Ổn định: Trong khi điều kiện kênh truyền thay đổi phức tạp, phương pháp JSC và các thuật toán Hybrid vẫn duy trì được đường đặc tính ổn định. Điều này cho thấy cơ chế tiến hóa đã thích nghi tốt với sự biến động của ma trận kênh truyền LOS.

Hiệu quả của Chuẩn hóa: Sự trùng khớp giữa Hybrid và JSC cho thấy các sai số tính toán số học (Floating-point errors) – vốn thường gây ra sự mất ổn định trong các thuật toán di truyền – đã được loại bỏ hoàn toàn nhờ bước Chuẩn hóa Công suất (Power Normalization) được thực hiện ngay trong quá trình tái tạo ma trận giúp đảm bảo mọi giải pháp thử nghiệm luôn tuân thủ nghiêm ngặt các ràng buộc vật lý về công suất phát trước khi đưa vào đánh giá hàm mục tiêu.

Sự Tương phản: Sự khác biệt rõ rệt giữa nhóm Hybrid (nằm trên đường tối ưu) và nhóm Original (dao động hỗn loạn ở mức thấp) là minh chứng rõ ràng nhất cho thấy sự cần thiết của việc tích hợp nghiệm giải tích làm điểm khởi đầu (Warm-Start) cho các bài toán tối ưu hóa vật lý phức tạp.

Việc phân bổ quần thể theo tỷ lệ 30% cá thể khai thác lân cận (tinh chỉnh quanh nghiệm tối ưu) và 70% cá thể khám phá toàn cục (mở rộng vùng tìm kiếm) giúp thuật toán vừa bảo toàn được hiệu năng cận dưới, vừa duy trì khả năng tìm kiếm các giải pháp đột phá ngoài vùng tối ưu cục bộ

3.4 Đánh giá độ phức tạp tính toán và khả năng thực thi

3.4.1. Phân tích độ phức tạp theo số chiều bài toán

Độ phức tạp của các thuật toán Tiến hóa (DE và SHADE) phụ thuộc trực tiếp vào số chiều của không gian tìm kiếm (D).

- Số chiều bài toán (D): Trong hệ thống Cell-free ISAC với $U = 5$ người dùng, $M = 2$ điểm truy cập và $N_t = 16$ ăng-ten, số chiều biến số thực là $D = 2 \times U \times M \times N_t = 320$ chiều.
- Chi phí tính toán: Với $G_{max} = 200$ thẻ hệ và kích thước quần thể $N = 50$, thuật toán thực hiện tổng cộng 10,000 lần đánh giá hàm mục tiêu. Tổng độ phức tạp được xác định là $O(G_{max} \cdot N \cdot (D + C_{fx}))$, trong đó C_{fx} là chi phí tính toán SINR và SNR cảm biến.

3.4.2. Hiệu quả hội tụ của cơ chế Lai ghép

- Tối ưu hóa quá trình khám phá: Việc sử dụng nghiệm từ phương pháp JSC (SDP) làm điểm khởi đầu (Warm-start) giúp thuật toán không phải tìm kiếm ngẫu nhiên trong không gian 320 chiều. Thay vào đó, thuật toán tập trung vào việc tinh chỉnh các vector búp sóng trong vùng lân cận tối ưu.
- Tính ổn định: Cơ chế thích nghi tham số trong SHADE (thông qua bộ nhớ lịch sử H) giúp tự động điều chỉnh hệ số co giãn F và tỷ lệ lai ghép CR , giúp thuật toán vượt qua các vùng yên ngựa (saddle points) trong không gian hàm mục tiêu không lồi của bài toán ISAC.

3.5. Nhận xét và kết luận

3.5.1. Nhận xét các phương pháp Differential Evolution

a) DE/SHADE Original

Ưu điểm

Khả năng khám phá (Exploration) tự do, không bị ràng buộc bởi các nghiệm có sẵn.
Không phụ thuộc vào các thuật toán giải tích phức tạp bên ngoài.

Nhược điểm

Rất khó tìm thấy vùng khả thi (Feasible Region) trong không gian tìm kiếm cực lớn (320 chiều) của hệ thống phi tế bào.

Tốc độ hội tụ chậm và dễ bị kẹt tại các cực trị địa phương có chất lượng kém (SINR xấp xỉ 0).

Chi phí tính toán lớn nhưng hiệu quả đạt được thấp đối với bài toán vật lý có ràng buộc chặt chẽ.

b) Hybrid DE/SHADE

Ưu điểm

Hội tụ nhanh và chính xác: Nhờ tận dụng nghiệm từ bài toán lồi (JSC) làm điểm khởi đầu (Warm-start).

Độ tin cậy cao: Áp dụng cơ chế "ngưỡng sàn" giúp tránh các bẫy cực trị địa phương, đảm bảo hiệu năng tối thiểu bằng với phương pháp giải tích.

Tính linh hoạt: Dễ dàng mở rộng sang các bài toán có ràng buộc phần cứng phi tuyến.

Nhược điểm

Phụ thuộc vào kết quả đầu vào từ một phương pháp tối ưu hóa khác (như SDP) để đạt hiệu năng tối đa.

Đòi hỏi thiết lập thông số quần thể phức tạp (phân chia tỷ lệ khai thác và khám phá) để đạt được sự cân bằng tối ưu.

3.5.2. Kết luận

Chiến lược khởi tạo: Việc sử dụng nghiệm của bài toán lồi (JSC) làm điểm khởi đầu cho thuật toán tiến hóa là yếu tố quyết định để đạt được sự hội tụ nhanh và chính xác.

Cơ chế đảm bảo chất lượng: Việc áp dụng một "ngưỡng sàn" dựa trên hiệu năng của phương pháp giải tích giúp thuật toán Meta-heuristic tránh được các bẫy cực trị địa phương kém chất lượng, đảm bảo độ tin cậy cao cho hệ thống. Điều này đặc biệt quan trọng trong mạng 6G nơi chất lượng dịch vụ (QoS) cần được cam kết nghiêm ngặt.

Tính ổn định và chuẩn hóa: Sự trùng khớp giữa kết quả của nhóm Hybrid và JSC chứng minh rằng các sai số tính toán số học đã được loại bỏ hoàn toàn thông qua bước chuẩn hóa công suất (Power Normalization) trong mã nguồn, giúp mọi giải pháp đều tuân thủ các giới hạn vật lý.

Khả năng ứng dụng: Mô hình đề xuất (Hybrid DE/SHADE) đã chứng minh được khả năng tiệm cận hoàn hảo với giới hạn lý thuyết. Cấu trúc này tạo tiền đề vững chắc để mở rộng sang các bài toán phức tạp hơn (như tối ưu hóa với ràng buộc phần cứng phi tuyến tính) mà các phương pháp giải tích truyền thống khó giải quyết, trong khi vẫn giữ được độ ổn định cần thiết.

Tài liệu tham khảo

1. Differential Evolution Algorithm With Strategy Adaptation for Global Numerical Optimization
https://www.researchgate.net/publication/224330344_Differential_Evolution_Algorithm_With_Strategy_Adaptation_for_Global_Numerical_Optimization
2. An Introduction to Differential Evolution
<https://www.maths.uq.edu.au/MASCOS/Multi-Agent04/Fleetwood.pdf>
3. Understanding working of Differential Evolution using step by step procedure
https://staff.emu.edu.tr/ahmetunveren/Documents/courses/CMPE536/Spring_24_25/Lectures/DE.pdf
4. Ensemble of differential evolution variants
https://www.math.ucdavis.edu/~saito/data/PSO-ACO/wu-etal_ensemble-diff-evol.pdf
5. JADE: Adaptive Differential Evolution with Optional External Archive
<https://troja.uksw.edu.pl/zasoby/SL2014-ZhangSanderson2009.pdf>
6. SHADE
<https://metahack.org/CEC2013-SHADE.pdf>
7. Cell-Free ISAC MIMO Systems: Joint Sensing and Communication Beamforming
<https://arxiv.org/pdf/2301.11328>